

Fundamentos de Infraestructura y Operaciones de IA

1. **¿Cuál de las siguientes opciones describe correctamente la arquitectura de referencia NVIDIA DGX BasePOD?**

- Proporciona componentes de infraestructura, redes y software para acelerar la implantación y ejecución de cargas de trabajo de IA.

Aclaración: DGX BasePOD es una solución integral para infraestructura de IA a escala.

2. **¿Cuál es el principal objetivo de la interconexión NVLink de NVIDIA en una configuración multi-GPU?**

- Para permitir la transferencia de datos a alta velocidad y la comunicación entre GPUs, significativamente más rápido que las velocidades de PCIe.

Aclaración: NVLink es crucial para el rendimiento en sistemas multi-GPU.

3. **¿Cómo mejora InfiniBand el rendimiento de las cargas de trabajo de IA?**

- Ofrece baja latencia, alto rendimiento y funciones inteligentes de descarga para optimizar el procesamiento de datos.

Aclaración: InfiniBand es especialmente beneficioso para aplicaciones de IA que requieren comunicación rápida entre nodos.

4. **¿Qué estrategia recomendarías para gestionar los costes y optimizar el rendimiento en la nube de tu proyecto de IA?**

- Adopte un enfoque híbrido en el que desarrolle e itere en las instalaciones y, a continuación, implemente a escala en la nube para equilibrar las necesidades de coste y rendimiento.

Aclaración: Este enfoque permite flexibilidad y control de costos.

5. **¿Cuál de los siguientes ejemplos ilustra la aplicación de la IA en el sector sanitario?**

- Análisis de imágenes en tiempo real para la identificación de células cancerosas.

Aclaración: Este es un ejemplo común de IA en medicina, mejorando la precisión diagnóstica.

6. **¿Por qué la gestión de la carga de trabajo y la supervisión se consideran tareas críticas en un clúster de IA?**

- Garantizan una asignación eficaz de los recursos, la programación de los trabajos y la comprobación del uso de los recursos.

Aclaración: Estas tareas son esenciales para maximizar la eficiencia y el rendimiento del clúster.

7. **¿Cuáles son las ventajas de utilizar las GPU para ejecutar cargas de trabajo de IA?**

- Las GPU proporcionan la capacidad de procesamiento paralelo necesaria para entrenar modelos de IA.

Aclaración: Las GPU son fundamentales para acelerar el entrenamiento de modelos de IA complejos.

8. **¿Cuándo se instalan GPU en un sistema de servidor, ¿qué factores hay que tener en cuenta para una configuración eficiente?*

- Equilibra las configuraciones de GPU en función de los requisitos de la carga de trabajo.

Aclaración: Es importante adaptar la configuración de GPU a las necesidades específicas de cada proyecto de IA.

9. **¿Cuál es una ventaja que pueden obtener las organizaciones al utilizar contenedores NGC?*

- Los contenedores NGC ayudan a desarrollar e implantar aplicaciones de IA en las GPU de forma más rápida y portátil.

Aclaración: NGC (NVIDIA GPU Cloud) proporciona contenedores optimizados para IA y HPC.

10. **¿Cuáles son las consideraciones clave de la infraestructura de almacenamiento para las cargas de trabajo de IA?*

- Velocidad, almacenamiento en caché y almacenamiento distribuido.

Aclaración: Estas características son cruciales para manejar grandes volúmenes de datos en IA.

11. **¿Cuál de las siguientes afirmaciones aborda mejor las consideraciones de la ejecución de cargas de trabajo de IA en redes Ethernet?*

- Las redes Ethernet pueden no ser tan eficientes como InfiniBand para cargas de trabajo de IA debido a su mayor latencia y menor ancho de banda.

Aclaración: Aunque Ethernet es común, InfiniBand suele ser preferible para IA de alto rendimiento.

12. **¿Qué solución de almacenamiento ofrece el mejor rendimiento global para las cargas de trabajo de IA?*

- Una solución de almacenamiento que ofrece IO de lectura rápida junto con almacenamiento en caché de datos.

Aclaración: La velocidad de lectura y el almacenamiento en caché son críticos para el rendimiento en IA.

13. **¿Cómo se utilizan los Modelos de lenguaje grande (LLM) en la inteligencia artificial generativa (GenAI)?*

- Los LLM se utilizan para generar textos similares a los humanos a partir de instrucciones de entrada.

Aclaración: Los LLM son la base de muchas aplicaciones de IA generativa, como chatbots avanzados.

14. **¿Cuál de las siguientes afirmaciones refleja mejor las características térmicas de las GPU?**

- Las GPU son conocidas por su elevada producción de calor en comparación con otros componentes informáticos.

Aclaración: La gestión térmica es un aspecto crucial en sistemas con múltiples GPU.

15. **¿Qué función caracteriza mejor a la tecnología NVIDIA NVSwitch?**

- Proporciona comunicación de GPU a GPU a velocidades increíblemente altas, especialmente durante las operaciones "todo a todo".

Aclaración: NVSwitch es clave para el rendimiento en sistemas con múltiples GPU.

16. **¿Qué aplicación de los años 80 ejemplificó uno de los primeros usos de la IA?**

- Filtros de spam.

Aclaración: Los filtros de spam fueron una de las primeras aplicaciones prácticas y exitosas de la IA.

17. **¿Qué factores han contribuido a que las GPU sean esenciales para los avances en el Aprendizaje profundo (AD)?

- Las GPU facilitan el procesamiento paralelo necesario para entrenar redes neuronales profundas de forma más eficiente.

Aclaración: La capacidad de procesamiento paralelo de las GPU ha sido crucial para el desarrollo del aprendizaje profundo.

18. **¿Cuáles son las ventajas de utilizar arquitecturas de referencia en el diseño de sistemas para entornos informáticos densos?

- Las arquitecturas de referencia esbozan diseños recomendados basados en el rendimiento medio del sistema.

Aclaración: Estas arquitecturas ayudan a optimizar el diseño y reducir el tiempo de implementación.

19. **¿Cuál es la diferencia entre la inteligencia artificial generativa (GenAI) y la IA tradicional?

- La IA generativa crea nuevos contenidos basándose en patrones aprendidos, mientras que la IA tradicional se centra en detectar patrones y tomar decisiones.

Aclaración: GenAI representa un avance significativo en la capacidad creativa de la IA.

20. **El software de GPU virtual NVIDIA (vGPU) ofrece las siguientes ventajas. Selecciona dos.

- Permite que varias máquinas virtuales tengan acceso directo a una única GPU física.
- Mejora la utilización de recursos al permitir que múltiples VMs compartan una GPU.

Aclaración: vGPU es crucial para la virtualización eficiente de recursos de GPU.

21. **¿Cuál de las siguientes opciones define mejor la función de una unidad de procesamiento de datos (DPU) en un entorno informático moderno?

- Aceleración del tráfico de red y descarga de tareas de la CPU del servidor.

Aclaración: Los DPU son importantes para optimizar el rendimiento de la red y liberar recursos de la CPU.

22. **¿Cuál de las siguientes opciones describe correctamente los métodos de refrigeración de los chips de GPU? Seleccione dos.**

- El aire frío es rentable, pero deja de ser eficiente a partir de 30 kW por rack.
- Los intercambiadores de calor refrigerados por agua son conocidos por su eficaz rechazo del calor y su mayor coste.

Aclaración: La elección del método de refrigeración depende de la densidad de potencia y el presupuesto.

23. **¿Cuál es el objetivo principal de Kubernetes?**

- Gestión y automatización de aplicaciones en contenedores.

Aclaración: Kubernetes es esencial para orquestar y escalar aplicaciones containerizadas.

24. **¿Cuál de las siguientes herramientas utilizaría para la gestión de la carga de trabajo, la programación y la priorización de trabajos, en un centro de datos de IA?**

- Slurm

Aclaración: Slurm es ampliamente utilizado en entornos de HPC y IA para la gestión de recursos.

25. **¿Cuál de las siguientes afirmaciones describe con exactitud la arquitectura Grace Hopper Superchip de NVIDIA?**

- Combina la CPU Grace con la GPU H100 a través de la interconexión NVLink de gran ancho de banda.

Aclaración: Esta arquitectura representa un avance significativo en la integración de CPU y GPU para IA y HPC.